TEMPLATE — M2: DATA QUALITY REPORT

Exploratory Data Analysis (KMTI21133) · Bobot 10% · Dikumpulkan pada pertemuan 5

Nama tim	EDA EDA AJA
Anggota dan peran	Firza Fadillah (Menganalisis dan Memecahkan masalah) Muhammad Fawwaz Abqory (Membuat Laporan dan Mencari Data) Adli Abdurrahman Syah (Mengelola GitHub) Ryuzan Zachry Maliq (Membantu Memecahkan masalah)
Judul proyek	Analisis Faktor-Faktor yang Memengaruhi Pendapatan Sektor Pariwisata Global
Pertanyaan payung	Apakah rata-rata pendapatan pariwisata (Revenue) dipengaruhi oleh jumlah pengunjung (Visitors) dan rating di berbagai negara?
Dataset	Tourism / https://www.kaggle.com/datasets/umeradnaan/tourism-dataset
Tautan repositori	https://github.com/ryuzanzachrymaliq/Exploratory-Data-Analysis.git
Tanggal laporan	12/10/2026

1. Ringkasan

Dataset yang digunakan dalam proyek Analisis Faktor-Faktor yang Memengaruhi Pendapatan Sektor Pariwisata Global ini berukuran 5.989 baris dan 7 kolom, yang memuat data lokasi, negara, kategori wisata, jumlah pengunjung, rating, pendapatan, serta ketersediaan akomodasi. Meskipun tergolong lengkap tanpa data kosong, ditemukan tiga masalah utama pada dataset ini, yaitu pola pendapatan yang terdistribusi acak tanpa korelasi linier yang kuat terhadap variabel pengunjung, nama lokasi berbentuk kode acak yang membatasi analisis spasial spesifik, dan ketiadaan komponen waktu untuk mengukur dampak musiman. Guna mengatasi keterbatasan tersebut, keputusan paling berpengaruh yang diambil adalah melakukan transformasi fitur dan berfokus pada analisis regresi agregat berbasis kategori wisata serta ketersediaan fasilitas pendukung. Secara keseluruhan, data ini sangat layak dianalisis karena memiliki tingkat kebersihan yang tinggi dan variabel inti yang relevan untuk mengevaluasi faktor pemicu pendapatan dalam industri pariwisata.

2. Data dan cara memeriksanya

2.1 Asal data

Butir	Isi
Nama sumber	Kaggle / Shaik Barood Mohammed Umar Adnaan Faiz
Tautan atau instansi	https://www.kaggle.com/datasets/umeradnaan/tourism-dataset
Tanggal pengambilan	25 September 2026
Lisensi atau nomor izin	CC0:Public Domain
Kalimat sitasi	Faiz, 2026

2.2 Ukuran dan cakupan

Berdasarkan struktur data pada dataset tourism_dataset.csv untuk proyek "Analisis Faktor-Faktor yang Memengaruhi Pendapatan Sektor Pariwisata Global", berikut adalah rinciannya:

- Jumlah Baris dan Kolom: Dataset ini terdiri dari 5.989 baris dan 7 kolom.
- Satuan Amatan (Satu baris mewakili apa): Setiap satu baris dalam dataset ini mewakili satu destinasi atau lokasi wisata tertentu di suatu negara, yang merangkum informasi mengenai kategori wisata, jumlah pengunjung, rating kepuasan, total pendapatan, serta ketersediaan akomodasi.
- Rentang Waktu yang Tercakup: Dataset ini tidak mencakup rentang waktu (tidak memiliki kolom tanggal, bulan, atau tahun). Data ini bersifat *cross-sectional* (potong lintang), yang berarti merupakan akumulasi atau rekapitulasi data global secara umum tanpa terikat pada periode waktu tertentu.

2.3 Cara pemeriksaan

Dalam analisis data ini, pemeriksaan yang dijalankan meliputi pengecekan integritas struktur data seperti jumlah baris dan kolom, validasi nilai kosong (*missing values*) serta duplikasi baris, pemeriksaan tipe data, perhitungan statistik deskriptif dasar, hingga analisis korelasi antarvariabel numerik menggunakan bahasa pemrograman Python dengan pustaka Pandas. Alat utama yang digunakan adalah Google Colab berlandaskan *Python Interpreter* untuk mengeksekusi skrip pemrosesan data secara cepat dan akurat. Namun, pemeriksaan lanjutan berbasis waktu atau tren musiman belum dapat dilakukan karena dataset ini tidak memiliki kolom waktu, tanggal, atau tahun (*time-series*), sehingga analisis tren historis temporal tidak dapat dieksplorasi lebih jauh.

3. Temuan kualitas data

Dimensi	Kolom	Masalah	Jumlah	Keparahan	Keputusan
Kelengkapan	Semua Kolom (*Location, Country, Category, Visitors, Rating, Revenue, Accommodation_Available*)	Tidak ditemukan data yang hilang (*missing values*); seluruh 5.989 baris terisi penuh.	0	Rendah	Dipertahankan (data siap dianalisis tanpa perlu *imputation*).
Keunikan	Seluruh Baris (*Row-level*)	Tidak ditemukan baris duplikat secara keseluruhan.	0	Rendah	Dipertahankan (tidak ada penghapusan baris duplikat).
Validitas	Location	Format nama lokasi berupa kode/string acak (misal: *kuBZRkVsAR*), bukan nama asli destinasi wisata.	5.989	Tinggi	Diabaikan untuk identifikasi spesifik; data lokasi dijadikan variabel kunci unik (ID) saja.
Validitas	Waktu / Tanggal	Dataset tidak memiliki kolom temporal (tanggal/tahun/bulan) untuk mengukur tren musiman.	-	Tinggi	Membatasi ruang lingkup analisis hanya pada analisis *cross-sectional* (bukan *time-series*).
Akurasi	Revenue & Rating	Pola distribusi nilai pendapatan dan rating terdistribusi seragam/acak tanpa korelasi linier dengan Visitors.	5.989	Sedang	Dilakukan agregasi data (mean/median per kategori & negara) untuk mengurangi *noise*.
Konsistensi	Accommodation_Available	Nilai bersifat kategorial biner (*Yes* / *No*) dan sudah konsisten secara format.	0	Rendah	Dipertahankan (siap digunakan langsung sebagai variabel kategorikal).

3.1 Pola nilai kosong

Kolom	Persen kosong	Dugaan	Dasar dugaan

4. Keputusan pembersihan dan alasannya

Keputusan tim Anda

Keputusan 1

Masalah	Dataset sama sekali tidak memiliki kolom tanggal, bulan, atau tahun (*timestamp*).
Dugaan pola	Dataset dirancang sebagai ringkasan potong lintang (*cross-sectional snapshot*) kumulatif global, bukan data transaksional berderet waktu.
Keputusan	Tidak melakukan imputasi atau penambahan kolom tanggal sintetis, melainkan mendeklarasikan dataset sebagai data *cross-sectional*.
Alasan	Menambahkan tanggal secara asal-asalan akan menciptakan bias temporal palsu dan merusak integritas analisis statistik.
Alternatif ditolak	Melakukan interpolasi tanggal otomatis untuk membuat tren bulanan ditolak karena melanggar keaslian data dan memicu kesimpulan keliru (*false insights*).
Dampak	Analisis dibatasi pada perbandingan antar-kategori dan korelasi antar-variabel secara global tanpa kemampuan melacak tren pertumbuhan historis dari waktu ke waktu.

Keputusan 2

Masalah	Kolom Location berisi string acak (misalnya: kuBZRkVsAR) yang tidak merepresentasikan nama destinasi wisata geografis nyata.
Dugaan pola	Data dihasilkan secara artifisial atau dianonimkan oleh sistem sumber tanpa pemetaan teks asli.
Keputusan	Membiarkan format string acak tersebut apa adanya dan memperlakukannya strictly sebagai *ID Unik Baris* (*Row Identifier*).
Alasan	Karena setiap baris sudah unik dan tidak ada baris yang duplikat, kode acak ini tetap valid digunakan sebagai penanda identitas destinasi individual tanpa mengganggu perhitungan statistik agregat.
Alternatif ditolak	Melakukan *mapping* atau penggantian nama manual ke destinasi dunia nyata ditolak karena akan memakan waktu tidak realistis dan berisiko menciptakan halusinasi data.
Dampak	Analisis spasial mendalam berbasis nama tempat spesifik tidak dapat dilakukan, sehingga fokus analisis dialihkan sepenuhnya ke level negara (Country) dan kategori wisata (Category).

Keputusan 3

Masalah	Distribusi nilai pada kolom pendapatan (*Revenue*) dan pengunjung (*Visitors*) tersebar merata dari skala kecil hingga mendekati 1.000.000 tanpa korelasi linier yang kuat.
Dugaan pola	Variabel numerik disimulasikan menggunakan distribusi seragam (*uniform distribution*) acak pada proses pembuatan data sintetik.
Keputusan	Melakukan transformasi logaritma atau pengelompokan berbasis kuantil (*binning*) saat visualisasi, serta menggunakan analisis non-parametrik atau agregasi rata-rata per kelompok.
Alasan	Penggunaan rata-rata mentah rentan terdistorsi jika terdapat outlier ekstrem, sehingga pengelompokan agregat memberikan gambaran pola yang lebih stabil.
Alternatif ditolak	Menghapus baris yang memiliki nilai pendapatan ekstrem ditolak karena nilai-nilai tersebut murni bagian dari sebaran data asli (bukan *error* pengetikan).
Dampak	Hubungan sebab-akibat langsung antara pengunjung dan pendapatan terlihat lemah, sehingga interpretasi analisis diarahkan pada perbandingan tren kelompok kategori wisata.

5. Dampak pembersihan terhadap data

5.1 Sebelum dan sesudah

Ukuran	Sebelum	Sesudah	Catatan
Jumlah baris	5.989	5.989	Tidak ada pemotongan atau penghapusan baris karena seluruh data awal valid dan lengkap.
Jumlah kolom	7	8	Menambahkan 1 kolom baru hasil enkoding biner (Accommodation_Numeric: 1 untuk *Yes*, 0 untuk *No*) untuk pemodelan analisis.
Total sel kosong	0	0	Data awal tidak memiliki *missing values* (0 sel kosong) dan tidak ada *placeholder* terselubung yang perlu diubah menjadi kosong.
Baris duplikat	0	0	Tidak ditemukan baris duplikat penuh baik sebelum maupun sesudah proses pembersihan.
Jumlah kategori pada kolom kunci	6	6	Kolom kunci kategorikal Category terdiri dari 6 kategori unik (*Nature, Historical, Cultural, Beach, Adventure, Urban*) tanpa ada kesalahan pengetikan/spasi berlebih.
Nilai unik pada kolom identitas	5.989	5.989	Kolom identitas Location memiliki 5.989 nilai unik yang menandai setiap baris destinasi secara spesifik.

5.2 Dampak terhadap sebaran

Kolom	Mean sebelum	Mean sesudah	Pergeseran	Penilaian
Revenue	499,479.37	499,479.37	**0 (Tetap)**	Tidak ada pergeseran sebaran sama sekali karena tidak dilakukan penghapusan baris maupun imputasi nilai ekstrem pada kolom pendapatan.
Visitors	501,016.09	501,016.09	**0 (Tetap)**	Sebaran data jumlah pengunjung tetap stabil karena integritas seluruh 5.989 baris dipertahankan secara utuh.
Rating	3.01	3.01	**0 (Tetap)**	Nilai rata-rata kepuasan wisatawan tidak mengalami perubahan karena tidak ada modifikasi atau pembuangan data anomali.

6. Keterbatasan

- Kolom yang datanya tidak dapat dipulihkan, dan pertanyaan analisis mana yang terdampak :

  Kolom Location berisi string acak berupa kode terenkripsi (misalnya *kuBZRkVsAR*) yang tidak merepresentasikan nama destinasi geografis nyata. Akibatnya, analisis spasial mendalam, pemetaan peta geografis (*geographic mapping*), dan identifikasi tempat wisata spesifik di dunia nyata tidak dapat dilakukan. Dampak pada kesimpulan adalah analisis harus dibatasi pada tingkat agregat global, perbandingan antar-negara (Country), dan kategori wisata (Category) tanpa bisa merujuk pada objek destinasi fisik yang sebenarnya.

- Dugaan MNAR yang tidak dapat dibuktikan, beserta arah kesalahannya :

  Meskipun dataset ini tidak memiliki nilai kosong secara teknis (0% missing values), terdapat indikasi variabel buatan/sintetik pada kolom pendapatan (Revenue) dan jumlah pengunjung (Visitors) yang terdistribusi secara seragam tanpa korelasi linier yang kuat. Jika diasumsikan terdapat hidden missingness atau data tersembunyi yang tidak tercatat (bersifat MNAR) pada destinasi berkinerja sangat rendah atau sangat tinggi, arah kesalahannya cenderung membuat estimasi rata-rata statistik global menjadi terlalu besar atau bias ke tengah (central tendency bias), sehingga melemahkan kemampuan model untuk mendeteksi anomali ekstrem di lapangan.

- Pemeriksaan yang belum dapat dilakukan dan alasannya :

  Pemeriksaan berbasis tren waktu (time-series analysis / tren musiman bulanan atau tahunan) sama sekali belum dapat dilakukan karena dataset ini tidak memiliki variabel tanggal, bulan, atau tahun. Dataset ini murni berbentuk potong lintang (cross-sectional snapshot), sehingga alasan utamanya adalah keterbatasan struktur data yang tidak merekam riwayat historis waktu operasional destinasi.

- Asumsi yang Anda ambil dan perlu dikonfirmasi ke pemilik data :

  Analisis ini berasumsi bahwa:

  1. Seluruh variabel numerik (Visitors, Rating, Revenue) dikumpulkan dengan standar metrik pengukuran yang seragam di seluruh negara.
  2. Variabel biner Accommodation_Available merepresentasikan ketersediaan akomodasi yang aktif dan dapat diakses oleh pengunjung di lokasi tersebut. *Asumsi-asumsi ini perlu dikonfirmasi kembali kepada pemilik data (pembuat dataset)* guna memastikan apakah angka-angka tersebut merupakan data riil industri pariwisata atau sekadar hasil simulasi generator data buatan (*synthetic data*).

7. Penanganan data pribadi

Butir	Keterangan
Kolom data pribadi pada data olahan	Tidak ada (Sebab dataset hanya memuat agregat lokasi, negara, kategori wisata, jumlah pengunjung, rating, pendapatan, dan ketersediaan akomodasi. Tidak ada data identitas pribadi atau PII seperti nama orang, nomor telepon, email, maupun NIK).
Tindakan penanganan yang diterapkan	Penganonimkan (Anonimisasi) Otomatis pada Kolom Lokasi (Kolom Location sudah terenkripsi menjadi kode/string acak sejak sumber awal, sehingga lokasi fisik spesifik dan data sensitif tidak dapat diidentifikasi secara langsung).
Nilai k pada data yang diunggah	N/A (Tidak Berlaku) / $k \geq 5.989$ (Tidak diterapkan teknik k-anonymity secara khusus karena data tidak mengandung kombinasi kuasi-identifikator pribadi).
Status repositori (publik atau privat)	Publik (Dataset bersifat data terbuka/sintetik pariwisata umum tanpa adanya potensi bahaya kebocoran data pribadi).
data/raw/ masuk .gitignore	Ya (Folder data/raw/ didaftarkan ke dalam file .gitignore untuk mematuhi praktik terbaik manajemen repositori dan memastikan dataset mentah asli tidak terunggah secara tidak sengaja).

8. Langkah berikutnya

- Melakukan Analisis Eksplorasi Data (EDA) Univariat & Bivariat: Menyusun visualisasi distribusi fitur numerik (Visitors, Rating, Revenue) serta analisis agregasi berbasis kelompok Category dan Country pada notebook M3 untuk memetakan pola pendapatan pariwisata.

- Membangun Pemodelan Prediktif Awal (Baseline Model): Menerapkan algoritma regresi sederhana untuk mengevaluasi sejauh mana variabel fitur dapat memprediksi variabel target Revenue.

- Konfirmasi Asumsi Data ke Dosen/Pemilik Data: Mengonfirmasi apakah rentang data Revenue dan Visitors merupakan akumulasi tahunan atau snapshot, serta menanyakan apakah perlu dibuat feature engineering baru (seperti Revenue per Visitor) untuk meningkatkan korelasi model.

Lampiran A — Cleaning log

#	Langkah	Baris terdampak	Alasan
1	Validasi *missing values* dan duplikasi baris penuh pada seluruh kolom.	0 baris (0%)	Memastikan tidak ada data kosong atau data ganda sebelum dilakukan analisis.
2	Menghapus spasi berlebih (*trimming whitespace*) pada kolom kategorial (Country, Category).	5.989 baris (100%)	Memastikan konsistensi penulisan nama kategori dan negara.
3	Menjadikan kolom Location sebagai penanda identitas unik (*Row Identifier*).	5.989 baris (100%)	Kode acak dipertahankan tanpa perubahan karena digunakan sebagai ID unik destinasi.
4	Pembuatan fitur biner baru Accommodation_Numeric dari kolom Accommodation_Available (1 untuk *Yes*, 0 untuk *No*).	5.989 baris (100%)	Mengonversi data kategorikal biner menjadi variabel numerik agar siap digunakan dalam algoritma pemodelan/regresi.
5	Pemeriksaan rentang nilai (*range check*) dan tipe data pada variabel numerik (Visitors, Rating, Revenue).	5.989 baris (100%)	Memastikan tidak ada nilai negatif atau tipe data yang tidak sesuai (*out-of-range/type mismatch*).

Lampiran B — Peta keputusan manual

Nilai asal / Kondisi asal	Diubah menjadi / Tindakan	Dasar keputusan
Tidak ada kolom tanggal / *timestamp*	Dideklarasikan sebagai data *cross-sectional*	Menghindari *bias* temporal dan pembuatan tren waktu palsu. Interpolasi tanggal ditolak untuk menjaga keaslian data.
Location: Kode string acak *(misal: kuBZRkVsAR)*	Dipertahankan sebagai ID Unik Baris (*Row Identifier*)	Mengingat seluruh baris unik, format acak dipertahankan apa adanya. *Mapping* manual ke destinasi dunia nyata ditolak karena berisiko memicu halusinasi data.
Revenue & Visitors: Distribusi seragam acak (skala $1 - 10^6$)	Transformasi logaritma / *Binning* (Pengelompokan kuantil)	Menghindari distorsi statistik dari sebaran acak. Menghapus baris nilai ekstrem ditolak karena nilai tersebut merupakan sebaran asli data (bukan *error* pengetikan).

Daftar periksa sebelum mengumpulkan

- Seluruh teks petunjuk bercetak miring sudah dihapus
- Setiap temuan pada Bagian 3 punya keputusan yang bersesuaian di Bagian 4
- Minimal satu keputusan menyebutkan alternatif yang ditolak
- Dampak terhadap sebaran ditunjukkan untuk minimal satu kolom
- Keterbatasan diisi, dan tidak berbunyi "tidak ada keterbatasan"
- Notebook berjalan dari awal sampai akhir setelah Restart and run all
- cleaning_log.md ada di akar repositori
- data/raw/ tidak berubah dan tidak ikut diunggah
- Perintah `python cek_m2.py` berjalan tanpa status GAGAL